Er reproduserbarhet nok?

Vibecke Håstø

onsdag 23 sep., 2026

Sammendrag Oppgaven drøfter om reproduserbarhet alene er nok for å stole på forskningsresultater. Den skiller først reproduserbarhet fra replikerbarhet og generaliserbarhet. Gjennom eksempler fra ulike fagfelt vises det at selv reproduserbare studier ofte ikke lar seg replikere og at økonomifaget sliter med at selv grunnleggende reproduserbarhetskravet sjelden innfris i praksis, blant annet på grunn av publiseringsskjevhet og selektiv rapportering.

Konklusjonen er at reproduserbarhet bør være et minstekrav for publisering fordi det er billig å oppnå, mens replikasjon heller bør stimuleres gjennom egne insentiver siden det er mer ressurskrevende. Verktøy som Quarto løser det tekniske reproduserbarhetsproblemet, men gjør ingenting med insentivproblemene bak replikasjonskrisen - reproduserbarhet er derfor nødvendig, men ikke tilstrekkelig, for pålitelig forskning.

Introduksjon

Reproduserbarhet handler om hvordan andre kan gjenskape forskningsresultater fra den opprinnelige utførte studien. De siste årene har mange fagfelt, inkludert innenfor økonomi, blitt kritisert for at en stor del av publiserte resultater ikke lar seg reprodusere (McNutt, 2014). Denne oppgaven ser nærmere på hva reproduserbarhet faktisk innebærer, hvordan begrepet skiller seg fra replikerbarhet og generaliserbarhet og hvilke tiltak som er forsøkt for å gjøre forskning mer etterprøvbar. Målet er å drøfte om reproduserbarhet alene er nok for at man skal kunne stole på forskningsresultater. Dette er relevant fordi tillit til tidligere funn er selve grunnlaget forskere bygger videre på og fordi falske eller ikke-reproduserbare resultater er både kostbare og vanskelige å rette opp i senere (Simmons et al., 2011).

Litteraturgjennomgang

Reproduserbarhet, replikerbarhet og generaliserbarhet

Før man drøfter om reproduserbarhet er nok, må begrepet avklares. National Science Foundation skiller robust og pålitelig vitenskap ved hjelp av tre begreper: reproduserbarhet, replikerbarhet og generaliserbarhet. *Reproduserbarhet* handler om å gjenskape resultatene fra en studie ved å bruke nøyaktig samme data og kode som den opprinnelige studien. *Replikerbarhet* krever at man oppnår de samme resultatene med nye, selvstendig innsamlede

data og *generaliserbarhet* handler om hvorvidt funnene holder også i andre kontekster og populasjoner (Bollen et al., 2015). Goodman et al. (2016) viser til et lignende poeng: å kalle noe reproduserbart sier først og fremst at man i teorien kan gjenta prosedyren, det sier ingenting om hvorvidt selve funnet er sant eller om det ville holdt seg dersom noen andre gjennomførte studien på ny. Gundersen (2021) viser tydeligere til begrepet ved å skille reproduserbarhet fra repeterbarhet. Repeterbarhet er at de samme forskerne oppnår samme resultat når de gjentar sitt eget eksperiment, mens reproduserbarhet krever at et uavhengig forskerteam gjenskaper konklusjonen ved hjelp av dokumentasjonen som er delt av de opprinnelige forskerne. Han skiller mellom tre grader av reproduserbarhet: utfallsreproduserbarhet, analyse-reproduserbarhet og tolkningsreproduserbarhet. Utfallsreproduserbarhet vil si at resultatet blir identisk med opprinnelig eksperiment. Analysereproduserbarhet er at selve resultatet kan avvike så lenge samme analyse fører til samme tolkning. Tolkningsreproduserbarhet er at verken resultat eller analyse trenger å være like, så lenge konklusjonen forblir den samme. Denne inndelingen kan legges til grunn for spørsmålet Peng (2011) stiller: om reproduserbarhet i det hele tatt bør være et minstekrav for publisering innen beregningsorientert vitenskap.

Hvorfor reproduserbarhet ikke er nok

Flere store replikasjonsstudier har vist at reproduserbarhet og replikerbarhet ikke er det samme i praksis. Nosek et al. (2015) forsøkte å replikere 100 psykologistudier fra tre anerkjente tidsskrifter, og fant at bare 36 prosent av replikasjonene ga signifikante resultater, mot 97 prosent i de opprinnelige studiene. En lignende undersøkelse av Klein et al. (2018) tok for seg 28 klassiske funn og fant at bare 54 prosent lot seg replikere. Ingen av disse studiene bestrider at de opprinnelige resultatene i utgangspunktet var reproduserbare: koden kjørte, og tallene stemte. Problemet oppstår først når andre forskere, med nye data, forsøker å bekrefte de samme konklusjonene. Ifølge Ioannidis (2005) kan falske funn utgjøre flertallet av publiserte forskningsresultater i enkelte fagfelt. Mekanismer som publiseringsskjevhet og type 1-feil bidrar til dette gapet. Tidsskrifter publiserer i stor grad signifikante funn, mens studier som ikke finner noen effekt sjelden når frem, som omtales som «File Drawer Problem» (Rosenthal, 1979). Simmons et al. (2011) peker på at falske positive resultater derfor kan være den mest kostbare feilen i forskning, nettopp fordi de er vanskelige å avkrefte i ettertid.

Erfaringer fra økonomifaget

Innen økonometri er situasjonen ofte enda mer grunnleggende: selv ren reproduserbarhet er vanskelig å oppnå. Dewald et al. (1986) sto bak Journal of Money, Credit and Banking-prosjektet, som forsøkte å etterprøve over 70 publiserte studier ved å be forfatterne om data og kode, men oppnådde full reproduksjon for kun to av dem. Selv etter at tidsskrifter innførte dataarkiver som skulle løse problemet, viste McCullough et al. (2008) at resultater publisert med tilgjengelig data og kode likevel sjelden lot seg reprodusere i praksis. Nyere studier bekrefter at problemet vedvarer: Chang & Li (2015) forsøkte å reprodusere 67 artikler fra 13 ledende økonomitidsskrifter og konkluderte med at resultatene som regel ikke kunne gjenskapes, selv ved tilgang til forfatternes egne data og kode. Duvendack et al. (2015) peker samtidig på et strukturelt problem: svært få replikasjonsstudier i økonomifaget blir i det hele tatt gjennomført eller publisert, fordi tidsskrifter sjelden prioriterer denne typen forskning. Necker (2014) underbygger dette med en spørreundersøkelse blant 426 europeiske økonomer, som viser at praksiser med lav vitenskapelig integritet er utbredt i faget. 32 prosent innrømmer

å ha presentert resultater selektivt og over en tredjedel har søkt etter kontrollvariabler eller stoppet analysen når de fikk ønskede resultater.

Diskusjon av forskningsspørsmålet

Burde replikerbarhet være et krav eller er det å be om for mye?

Å kreve full replikerbarhet, at enhver studie skal bekreftes med helt nye, uavhengige data før publisering, ville i praksis stanse store deler av forskningen. Dette skyldes at datainnsamling ofte er tid- og ressurskrevende. Samtidig viser Duvendack et al. (2015) at når replikasjon ikke er noe krav og det ikke er tidsskrifter som er villige til å publisere replikasjonsstudier, vil trolig bare et fåtall slike studier bli gjennomført. En mulig mellomløsning er å skille kravene: reproduserbarhet bør være et minstekrav for publisering, ettersom det ifølge Peng (2011) kan oppnås til svært lav kostnad. Replikerbarhet er derimot mer ressurskrevende og bør heller skje gjennom egne insentiver, for eksempel at tidsskrifter setter av fast plass til replikasjonsstudier.

Kan Quarto dokumenter hjelpe med å oppnå reproduserbarhet?

Verktøy for «beregnbare dokumenter» har vokst frem nettopp for å gjøre reproduserbarhet enklere. Sweave Leisch (2002) og senere Knitr Xie (2015) gjorde det mulig å kombinere kjørbar kode og tekst i samme dokument, men R Markdown Allaire et al. (2020) og utviklingsmiljøet RStudio RStudio Team (2020) bygget videre på denne ideen. Quarto er en nyere utvikling og videreføring av dette og kan generere output i flere formater samtidig som det støtter kode, referanser og matematikk i ett og samme dokument. Dette gjør det mulig å oppnå det Gundersen (2021) kaller den høyeste graden av reproduserbarhet - der tekst, kode og data deles samlet, tilsvarende Gentleman & Temple Lang (2007) sitt begrep «compendium». Quarto løser dermed det tekniske reproduserbarhetsproblemet på en god måte. Verktøyet er derimot ingen garanti i seg selv: det sikrer bare at koden kan kjøres på nytt av andre; det gjør ingenting med publiseringsskjevhet, insentivproblemer eller manglende generaliserbarhet. Quarto er med andre ord et nødvendig, men ikke tilstrekkelig verktøy for robust og pålitelig vitenskap.

Hvilke problem gjenstår og hvordan kan disse løses?

Selv med gode verktøy for reproduserbarhet gjenstår flere strukturelle problemer. For det første er insentivene fortsatt skjeve. Tidsskrifter foretrekker nye, signifikante funn fremfor replikasjoner Duvendack et al. (2015), noe som opprettholder publiseringsskjevheten. For det andre viser Necker (2014) at uheldig forskningspraksis som selektiv rapportering fortsatt er vanlig, uavhengig av hvilke tekniske verktøy som finnes. For det tredje er ikke engang tekniske dataarkiver noen garanti, ettersom McCullough et al. (2008) fant at arkivert data og kode sjelden faktisk brukes til å reprodusere resultater. Mulige løsninger inkluderer sterkere krav fra tidsskrifter om at data og kode må deles ved innsending (ikke bare oppfordres), egne publiseringskanaler for replikasjonsstudier og nullfunn, samt bruk av verktøy som renv for å sikre at pakkeversjoner ikke endrer resultatene over tid. Ingen av disse løsningene virker alene, men det kreves en kombinasjon av tekniske løsninger og endrede insentiver i forskersamfunnet.

Konklusjon

Reproduserbarhet er en nødvendig, men ikke tilstrekkelig forutsetning for pålitelig forskning. Det sikrer at andre kan etterprøve at man har gjort det man sier man har gjort, men sier lite

om hvorvidt konklusjonen faktisk er sann eller holder i andre sammenhenger. Erfaringene fra økonomifaget viser dessuten at selv dette minstekravet ofte ikke innfris i praksis. Verktøy som Quarto gjør den tekniske jobben enklere, men løser ikke insentivproblemene som ligger bak replikasjonskrisen. Skal forskning virkelig fortjene tillit, må teknisk åpenhet derfor følges av en kultur der replikasjon verdsettes like høyt som nye funn.

Referanser

Allaire, J., Xie, Y., McPherson, J., Luraschi, J., Ushey, K., Atkins, A., Wickham, H., Cheng, J., Chang, W., & Iannone, R. (2020). *Rmarkdown: Dynamic documents for r*.

Bollen, K., Cacioppo, J. T., Krosnick, J. A., Olds, J. L., & Kaplan, R. M. (2015). *Social, Behavioral, and Economic Sciences Perspectives on Robust and Reliable Science*.

Chang, A. C., & Li, P. (2015). *Is Economics Research Replicable? Sixty Published Papers from Thirteen Journals Say 'Usually Not'* (s. 26). https://doi.org/http://dx.doi.org/10.17016/FEDS.2015.083

Dewald, W. G., Thursby, J. G., & Anderson, R. G. (1986). Replication in Empirical Economics: The Journal of Money, Credit and Banking Project. *The American Economic Review*, *76*(4), 587603.

Duvendack, M., Palmer-Jones, R. W., & Reed, R. (2015). Replications in Economics: A Progress Report. *Econ Journal Watch*, *12*(2), 164–191.

Gentleman, R., & Temple Lang, D. (2007). Statistical Analyses and Reproducible Research. *Journal of Computational and Graphical Statistics*, *16*(1), 123.

Goodman, S. N., Fanelli, D., & Ioannidis, J. P. A. (2016). What does research reproducibility mean? *Science Translational Medicine*, *8*(341), 341ps12–341ps12.

Gundersen, O. E. (2021). *The fundamental principles of reproducibility*. *379*(2197), 15. https://www.jstor.org/stable/27101180?casa_token=kQAO761tw5IAAAAA%3AT6ZOSHtDxIaTwLw92917I_8vNRpa1qPOH1UU02yM_h9L9lwFarcVViHkS1bjG6afN5zR6PsYNd0Zw5RCXJMXXhf0UXPySxZwuf-BTzvB-CqVyzNHtIpS&seq=1

Ioannidis, J. P. A. (2005). Why Most Published Research Findings Are False. *PLOS Medicine*, *2*(8), e124.

Klein, R. A., Vianello, M., Hasselman, F., Adams, B. G., Reginald B. Adams, Jr., Alper, S., Aveyard, M., Axt, J. R., Babalola, M. T., Bahník, Š., Batra, R., Berkics, M., Bernstein, M. J., Berry, D. R., Bialobrzeska, O., Binan, E. D., Bocian, K., Brandt, M. J., Busching, R., … Nosek, B. A. (2018). Many labs 2: Investigating variation in replicability across samples and settings. *Advances in Methods and Practices in Psychological Science*, *1*(4), 443490.

Leisch, F. (2002). *Sweave: Dynamic Generation of Statistical Reports Using Literate Data Analysis* (s. 575–580). Physica-Verlag HD. https://doi.org/DOI: 10.1007/978-3-642-57489-4_89

McCullough, B. D., McGeary, K. A., & Harrison, T. D. (2008). Do economics journal archives promote replicable research? *Canadian Journal of Economics/Revue Canadienne d'économique*, *41*(4), 14061420.

McNutt, M. (2014). Reproducibility. *Science*, *343*(6168), 229–229.

Necker, S. (2014). Scientific misbehavior in economics. *Research Policy*, *42*(10). https://doi.org/https://doi.org/10.1016/j.respol.2014.05.002

Nosek, B. A., Alter, G., Banks, G. C., Borsboom, D., Bowman, S. D., Breckler, S. J., Buck, S., Chambers, C. D., Chin, G., Christensen, G., Contestabile, M., Dafoe, A., Eich, E., Freese, J., Glennerster, R., Goroff, D., Green, D. P., Hesse, B., Humphreys, M., … Yarkoni, T. (2015). Promoting an Open Research Culture. *Science*, *348*(6242), 1422–1425.

Peng, R. D. (2011). Reproducible Research in Computational Science. *Science*, *334*(6060), 1226–1227.

Rosenthal, R. (1979). *The File Drawer Problem and Tolerance for Null Results.*

RStudio Team. (2020). *RStudio: Integrated Development Environment for r*. RStudio, PBC.

Simmons, J. P., Nelson, L. D., & Simonsohn, U. (2011). False-Positive Psychology: Undisclosed Flexibility in Data Collection and Analysis Allows Presenting Anything as Significant. *Psychological Science*, *22*(11), 1359–1366.

Xie, Y. (2015). *Dynamic Documents with R and Knitr* (Second). Chapman and Hall/CRC.

Appendiks A

R versjonen som er brukt R 4.6.1

R Core Team (2026). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria. doi:10.32614/R.manuals https://doi.org/10.32614/R.manuals. https://www.R-project.org/.

Wickham H, Averick M, Bryan J, Chang W, McGowan LD, François R, Grolemund G, Hayes A, Henry L, Hester J, Kuhn M, Pedersen TL, Miller E, Bache SM, Müller K, Ooms J, Robinson D, Seidel DP, Spinu V, Takahashi K, Vaughan D, Wilke C, Woo K, Yutani H (2019). «Welcome to the tidyverse.» *Journal of Open Source Software*, *4*(43), 1686. doi:10.21105/joss.01686 https://doi.org/10.21105/joss.01686.

Xie Y (2025). *knitr: A General-Purpose Package for Dynamic Report Generation in R*. R package version 1.51, https://yihui.org/knitr/.

Xie Y (2015). *Dynamic Documents with R and knitr*, 2nd edition. Chapman and Hall/CRC, Boca Raton, Florida. ISBN 978-1498716963, https://yihui.org/knitr/.

Xie Y (2014). «knitr: A Comprehensive Tool for Reproducible Research in R.» In Stodden V, Leisch F, Peng RD (eds.), *Implementing Reproducible Computational Research*. Chapman and Hall/CRC. ISBN 978-1466561595.

Appendiks B

I denne oppgaven er KI tjenesten Claude brukt, versjon Claude Sonnet 5. Den kunstige intelligensen er brukt til forståelse av kilder, rettelse av tekst og skrivefeil, hjelp med å skive et norsk sammendrag av presentasjonen «Robust and Reliable Science» og brukt for hjelp til Rstudio.

cse_01Lqf5SbkxMcCUeV378zj1Ph

cse_018LoHGRXu7wiC7524VZY97T

cse_01Ay19pzpbDrqBC9ksJJAhi3