

Er reproduserbarhet nok?

Vibecke Håstø

Monday 14 Sep, 2026

Abstract Et kort sammendrag, en til to avsnitt.

Introduksjon

Reproduserbarhet handler om hvordan andre kan gjenskape forskningsresultater fra den opprinnelige utførte studien. De siste årene har mange fagfelt, inkludert innenfor økonomi, blitt kritisert for at en stor del publiserte resultater ikke lar seg bli reproduert eller bekreftet (McNutt, 2014). Denne oppgaven ser nærmere på hva reproduserbarhet faktisk innebærer hvordan begrepet skiller seg fra replikerbarhet og generaliserbarhet og hvilke tiltak som er forsøkt for å gjøre forskning mer etterprøvbart. Målet er å drøfte om reproduserbarhet alene er nok for at en skal kunne stole på forskningsresultater. Dette er relevant fordi tillit til tidligere funn er selve grunnlaget forskere bygger videre på og fordi falske eller ikke-reproduerbare resultater er både kostbare og vanskelige å rette opp i senere (Simmons et al., 2011).

Litteraturgjennomgang

Reproduserbarhet, replikerbarhet og generaliserbarhet

Før man drøfter om reproduserbarhet er nok, må begrepet avklares. National Science Foundation skiller robust og pålitelig vitenskap med tre forskjellige begreper; reproduserbarhet, replikerbarhet og generaliserbarhet. Reproduserbarhet handler om å gjenskape resultatene fra en studie ved å bruke nøyaktig samme data og kode som den opprinnelige studien. Replikerbarhet krever at man oppnår de samme resultatene med nye, selvstendig innsamlede data og generaliserbarhet handler om hvorvidt funnene holder også i andre kontekster og populasjoner (Bollen et al., 2015). Goodman et al. (2016) viser til et lignende poeng: å kalle noe reproduserbart sier først og fremst at man i teorien kan gjenta prosedyren, det sier ingenting om hvorvidt selve funnet er sant eller om det ville holdt seg dersom noen andre gjennomførte studien på ny. Gundersen (2021) viser tydeligere til begrepet ved å skille reproduserbarhet fra replikerbarhet. Replikerbarhet er at de samme forskerne oppnår samme resultat når de gjentar sitt eget eksperiment, krever reproduserbarhet at et uavhengig forskerteam gjenskaper konklusjonen ved hjelp av dokumentasjonen som er delt av de opprinnelige forskerne. Han skiller mellom tre grader reproduserbarhet: utfallsreproduserbarhet, analyse-reproduserbarhet og tolkningsreproduserbarhet. Utfallsreproduserbarhet vil si der resultatet blir identisk med opprinnelig eksperiment, analyse-reproduserbarhet er der selve resultatet kan avvike så lange samme analyse fører til samme tolkning og tolkningsreproduserbarhet er der verken resultat

eller analyse trenger å være like, så lange konklusjonen forblir den samme. Denne inndelingen kan legges til grunn for spørsmålet Peng (2011) stiller: om reproduserbarhet i det hele tatt bør være et minstekrav for publisering innen beregningsorientert vitenskap.

Hvorfor reproduserbarhet ikke er nok

Flere store replikasjonsstudier har vist at reproduserbarhet og replikerbarhet ikke er det samme i praksis. Nosek et al. (2015) forsøkte å replikere 100 psykologistudier fra tre anerkjente tidsskrifter, og fant at bare 36 prosent av replikasjonene ga signifikante resultater, mot 97 prosent i de opprinnelige studiene. En lignende undersøkelse av Klein et al. (2018) tok for seg 28 klassiske funn og fant at bare 54 prosent lot seg replikere. Ingen av disse studiene bestrider at de opprinnelige resultatene i utgangspunktet var reproduserbare, koden kjørte, og tallene stemte. Problemet oppstår først når andre forskere, med nye data, forsøker å bekrefte de samme konklusjonene. Ifølge Ioannidis (2005) kan falske funn utgjøre flertallet av publiserte forskningskrav i enkelte fagfelt. Mekanismer som publiseringskjevhet og type 1-feil bidrar til dette gapet. Tidsskrifter publiserer i stor grad signifikante funn, mens studier som ikke finner noen effekt sjelden når frem, som omtales som skuffeeffekten (Rosenthal, 1979). Simmons et al. (2011) peker på at falske positive resultater derfor kan være den mest kostbare feilen i forskning, nettopp fordi de er vanskelige å avkrefte i ettertid.

Erfaringer fra økonomifaget

Innen økonometri er situasjonen ofte enda mer grunnleggende: selv ren reproduserbarhet er vanskelig å oppnå. Dewald et al. (1986) sto bak Journal of Money, Credit and Banking-prosjektet, som forsøkte å etterprøve over 70 publiserte studier ved å be forfatterne om data og kode, men oppnådde full replikasjon for kun to av dem. Selv etter at tidsskrifter innførte dataarkiver som skulle løse problemet, viste McCullough et al. (2008) at resultater publisert med tilgjengelig data og kode likevel sjelden lot seg reproducere i praksis. Nyere studier bekrefter at problemet vedvarer: Chang & Li (2015) forsøkte å replikere 67 artikler fra 13 ledende økonomitidsskrifter og konkluderte med at resultatene som regel ikke kunne gjenskapes, selv ved tilgang til forfatternes egne data og kode. Duvendack et al. (2015) peker samtidig på et strukturelt problem: svært få replikasjonsstudier i økonomifaget blir i det hele tatt gjennomført eller publisert, fordi tidsskrifter sjelden prioriterer denne typen forskning. Necker (2014) underbygger dette med en spørreundersøkelse blant 426 europeiske økonomer, som viser at praksiser med lav vitenskapelig integritet er utbredt i faget. 32 prosent innrømmer å ha presentert resultater selektivt og over en tredjedel har søkt etter kontrollvariabler eller stoppet analysen når de fikk ønsket resultater.

Diskusjon av forskningsspørsmålet (problemstillingen)

Burde replikerbarhet være et krav eller er det å be om for mye?

Å kreve full replikerbarhet, at enhver studie skal bekreftes med helt nye, uavhengige data før publisering, ville i praksis stanse store deler av forskningen. Dette på grunn av at datainnsamling ofte er tid- og ressurskrevende. Samtidig viser Duvendack et al. (2015) at når replikasjon ikke er noe krav og det ikke er tidsskrifter som er villige til å publisere replikasjonsstudier, vil trolig bare et fåtall slike studier blitt gjennomført. En mulig mellomløsning er å skille kravene: reproduserbarhet bør være minstekrav for publisering, ettersom det ifølge Peng (2011) kan oppnås til svært lav kostnad. Replikerbarhet er derimot mer ressurskrevende og bør heller skje gjennom egne insentiver, for eksempel at tidsskrifter setter av fast plass til replikasjonsstudier.

Kan Quarto dokumenter hjelpe med å oppnå reproduserbarhet?

Verktøy for «beregnbare dokumenter» har vokst frem nettopp for å gjøre reproduserbarhet enklere. Sweave Leisch (2002) og senere Knitr Xie (2015) gjorde det mulig å kombinere kjørbare kode og tekst i samme dokument, men R Markdown Allaire et al. (2020) og utviklingsmiljøet RStudio RStudio Team (2020) bygget videre på denne ideen. Quarto er en nyere utvikling og videreføring av dette og kan generere output i flere formater samtidig som det støtter kode, referanser og matematikk i ett og samme dokument. Dette gjør det mulig å oppnå det Gundersen (2021) kaller den høyeste graden av reproduserbarhet - der tekst, kode og data deles samlet, tilsvarende Gentleman & Temple Lang (2007) sitt begrep «compendium». Quarto løser dermed det tekniske reproduserbarhetsproblemet på en god måte. Verktøyet er derimot ingen garanti i seg selv: det sikrer bare at koden kan kjøres på nytt av andre, det gjør ingenting med publiseringsskjevhet, insentivproblemer eller manglende generaliserbarhet. Quarto er med andre ord et nødvendig, men ikke tilstrekkelig verktøy for robust og pålitelig vitenskap.

Hvilke problem gjenstår og hvordan kan disse løses?

Selv med gode verktøy for reproduserbarhet gjenstår flere strukturelle problemer. For det første er insentivene fortsatt skjeve. Tidsskrifter foretrekker nye, signifikante funn fremfor replikasjoner Duvendack et al. (2015), noe som opprettholder publiseringsskjevheten. For det andre viser Necker (2014) at uheldig forskningspraksis som selektiv rapportering fortsatt er vanlig, uavhengig av hvilke tekniske verktøy som finnes. For det tredje er ikke engang tekniske dataarkiver noe garanti, ettersom McCullough et al. (2008) fant at arkivert data og kode sjelden faktisk brukes til å reproducere resultater. Mulige løsninger inkluderer sterkere krav fra tidsskrifter om at data og kode må deles ved innsending (ikke bare oppfordres), egne publiseringkanaler for replikasjonsstudier og nullfunn, samt bruk av verktøy som rev for å sikre at pakkeversjoner ikke endrer resultatene over tid. Ingen av disse løsningene virker alene, det kreves en kombinasjon av tekniske løsninger og endrede insentiver i forskersamfunnet.

Konklusjon

Noen kloke ord.

Referanser

- Allaire, J., Xie, Y., McPherson, J., Luraschi, J., Ushey, K., Atkins, A., Wickham, H., Cheng, J., Chang, W., & Iannone, R. (2020). *Rmarkdown: Dynamic documents for r*.
- Bollen, K., Cacioppo, J. T., Krosnick, J. A., Olds, J. L., & Kaplan, R. M. (2015). *Social, behavioral, and economic sciences perspectives on robust and reliable science*.
- Chang, A. C., & Li, P. (2015). *Is economics research replicable? Sixty published papers from thirteen journals say 'usually not'* (p. 26). <https://doi.org/http://dx.doi.org/10.17016/FEDS.2015.083>
- Dewald, W. G., Thursby, J. G., & Anderson, R. G. (1986). Replication in empirical economics: The journal of money, credit and banking project. *The American Economic Review*, 76(4), 587-603.
- Duvendack, M., Palmer-Jones, R. W., & Reed, R. (2015). Replications in economics: A progress report. *Econ Journal Watch*, 12(2), 164–191.

- Gentleman, R., & Temple Lang, D. (2007). Statistical analyses and reproducible research. *Journal of Computational and Graphical Statistics*, 16(1), 123.
- Goodman, S. N., Fanelli, D., & Ioannidis, J. P. A. (2016). What does research reproducibility mean? *Science Translational Medicine*, 8(341), 341ps12–341ps12.
- Gundersen, O. E. (2021). *The fundamental principles of reproducibility*. 379(2197), 15. https://www.jstor.org/stable/27101180?casa_token=kQAO761tw5IAAAAA%3AT6ZOSHtDxIaTwLw92917I_8vNRpa1qPOH1UU02yM_h9L9lwFarcVViHkS1bjG6afN5zR6PsYNd0Zw5RCXJMXhF0UXPySxZwuf-BTzvB-CqVyzNHtlpS&seq=1
- Ioannidis, J. P. A. (2005). Why most published research findings are false. *PLOS Medicine*, 2(8), e124.
- Klein, R. A., Vianello, M., Hasselman, F., Adams, B. G., Reginald B. Adams, Jr., Alper, S., Aveyard, M., Axt, J. R., Babalola, M. T., Bahník, Š., Batra, R., Berkics, M., Bernstein, M. J., Berry, D. R., Bialobrzeska, O., Binan, E. D., Bocian, K., Brandt, M. J., Busching, R., ... Nosek, B. A. (2018). Many labs 2: Investigating variation in replicability across samples and settings. *Advances in Methods and Practices in Psychological Science*, 1(4), 443490.
- Leisch, F. (2002). *Sweave: Dynamic generation of statistical reports using literate data analysis* (pp. 575–580). Physica-Verlag HD. https://doi.org/DOI: 10.1007/978-3-642-57489-4_89
- McCullough, B. D., McGeary, K. A., & Harrison, T. D. (2008). Do economics journal archives promote replicable research? *Canadian Journal of Economics/Revue Canadienne d'économie*, 41(4), 14061420.
- McNutt, M. (2014). Reproducibility. *Science*, 343(6168), 229–229.
- Necker, S. (2014). Scientific misbehavior in economics. *Research Policy*, 42(10). <https://doi.org/https://doi.org/10.1016/j.respol.2014.05.002>
- Nosek, B. A., Alter, G., Banks, G. C., Borsboom, D., Bowman, S. D., Breckler, S. J., Buck, S., Chambers, C. D., Chin, G., Christensen, G., Contestabile, M., Dafoe, A., Eich, E., Freese, J., Glennerster, R., Goroff, D., Green, D. P., Hesse, B., Humphreys, M., ... Yarkoni, T. (2015). Promoting an open research culture. *Science*, 348(6242), 1422–1425.
- Peng, R. D. (2011). Reproducible Research in Computational Science. *Science*, 334(6060), 1226–1227.
- Rosenthal, R. (1979). *The file drawer problem and tolerance for null results*.
- RStudio Team. (2020). *RStudio: Integrated development environment for r*. RStudio, PBC.
- Simmons, J. P., Nelson, L. D., & Simonsohn, U. (2011). False-positive psychology: Undisclosed flexibility in data collection and analysis allows presenting anything as significant. *Psychological Science*, 22(11), 1359–1366.
- Xie, Y. (2015). *Dynamic documents with R and knitr* (Second). Chapman and Hall/CRC.

Appendiks A

- Versjon nummer og referanse til R pakken brukt i dokumentet
- R versjon brukt, med referanse

Appendiks B

- Hvordan er KI brukt
- Husk invitasjon til chat